### **OpenMP**

Arquitetura de Computadores Mestrado Integrado em Engenharia Informática

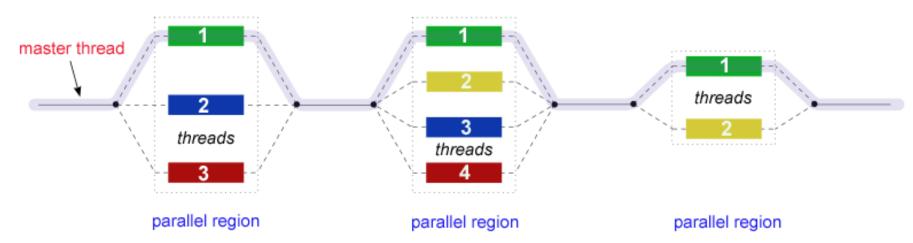
## O que é o OpenMP

### Open Multi Processing

- API para expressar paralelismo multi-threaded e de memória partilhada
- standard mantido pelo OpenMP Architecture Review Board
- Nov.2015 : versão 4.5 (maior parte dos compiladores suporta 4.0)
- Objectivos:
  - normalização (standard)
  - portabilidade
  - fácil utilização

 Criação explícita de blocos paralelos de código executados por um grupo (team) de threads

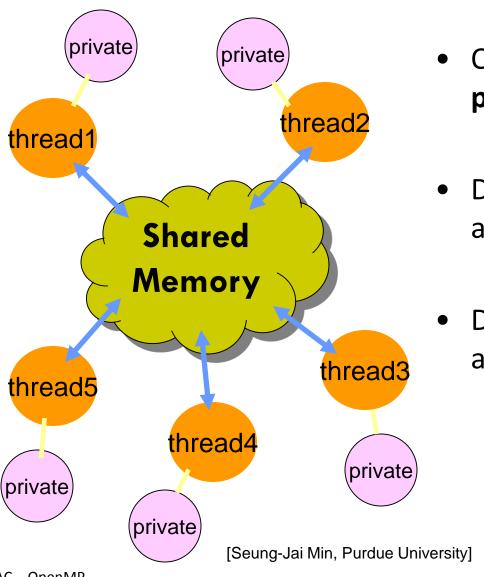
#### Modelo Fork & Join



- No final de cada bloco:
  - todas as threads sincronizam (barreira implícita)
  - todas as threads excepto a principal deixam de existir

```
printf("program begin\n");
N = 1000;
                                  Sequencial
#pragma omp parallel for
for (i=0; i<N; i++)
                                 Paralelo
    A[i] = B[i] + C[i];
                                  Sequencial
M = 500;
#pragma omp parallel for
                                 Paralelo
for (j=0; j<M; j++)
    p[j] = q[j] - r[j];
                                  Sequencial
printf("program done\n");
```

[Seung-Jai Min, Purdue University]



 Os dados podem ser partilhados ou privados

 Dados partilhados são acessíveis a todas as threads

 Dados privados são acessíveis apenas à thread que os possui

- Por defeito os dados são partilhados
- As variáveis globais a um bloco paralelo são partilhadas
- Variáveis privadas:
  - declaradas dentro de um bloco paralelo
  - explicitamente marcadas como privadas
  - índices de alguns ciclos for

### **Directivas**

• Paralelismo especificado usando directivas embebidas no código #pragma omp <nome directiva> [clásula,...]

Cada directiva aplica-se ao bloco de instruções que se lhe segue
 #pragma omp parallel
 ... // bloco paralelo

```
... // bloco sequencial
```

 O compilador ignora as directivas se não for usada a opção que activa o OpenMP. Exemplo:

```
gcc -fopenmp <filename>
icc -openmp <filename>
```

# Funções

#include <omp.h></omp.h>	
Função	Descrição
<pre>int omp_get_thread_num (void)</pre>	Devolve ID da thread
<pre>int omp_get_num_threads (void)</pre>	Devolve número de threads actualmente existentes num bloco paralelo
<pre>void omp_set_num_threads (int)</pre>	Estabelece número de threads a ser criadas no próximo bloco paralelo
<pre>int omp_get_num_procs (void)</pre>	Devolve número de processadores disponíveis para o programa
double omp_get_wtime (void)	Devolve um time stamp em segundos
e muitas mais	

### directiva parallel

```
#pragma omp parallel
{
    ... // bloco paralelo
}
```

- cria um grupo (team) de N threads
- cada uma desta threads executa independentemente o bloco paralelo
- no fim do bloco existe uma barreira (sincronização) implícita: a thread principal só continua depois de todas as outras também terem chegado ao fim do bloco

### directiva parallel

```
shared by default!

char *s = "Hello, world!";

#pragma omp parallel
{
   printf("%s\n",s);
}

printf("program done\n");
```

```
>./prog
Hello, world!
Hello, world!
program done
```

- Variáveis globais a um bloco paralelo são partilhadas por defeito
- São variáveis privadas:

```
    locais ao bloco
        #pragma omp parallel
        { int i;
            ... }
    explicitamente declaradas com a cláusula private (...)
            int x;
            #pragma omp parallel private (x)
    os índices de alguns ciclos (ver directiva for)
```

• A cláusula default (shared | private) permite alterar a situação por defeito

```
main () {
 int tid
 #pragma omp parallel
  tid = omp_get_thread_n\u00c4m();
  printf("Thread %d\n",tid);
 printf("program done\n");
```

variável partilhada onde várias threads escrevem sem qualquer controlo de acesso

Resultado indeterminado

variável privada

```
cada thread tem a sua
main () {
                                        própria instância local de
 int tid;
                                        tid
 #pragma omp parallel private
  tid = omp_get_thread_num();
printf("Thread %d\n",tid);
 printf("program done\n");
```

```
main () {
 #pragma omp parallel
  int tid;
  tid = omp_get_thread_num();
  printf("Thread %d\n",tid);
 printf("program done\n");
}
```

#### variável privada

cada *thread* tem a sua própria instância local de **tid** 

### directiva parallel

- Quantas threads há num grupo?
  - 1. cláusula num\_threads(int)
     #pragma omp parallel num\_threads(64)
  - 2. função omp\_set\_num\_threads(int)
     omp\_set\_num\_threads (12);
  - 3. variável de ambiente OMP\_NUM\_THREADS> export OMP NUM THREADS=8
  - 4. Por defeito: dependente da implementação normalmente igual ao número de processadores disponível para o programa

#### directiva for

- distribui as iterações do ciclo for pelas threads do grupo
- o índice do ciclo é privado a cada thread

```
#pragma omp parallel
{
 printf ("Hello\n");
  #pragma omp for
  for (i=0; i<N; i++) A[i] = B[i] + C[i];
}</pre>
```

- deve estar dentro de um bloco parallel
- por defeito a distribuição é estática:
  - as iterações são distribuídas pelas threads em chunks do mesmo tamanho e consecutivos

### directiva for

• for e parallel podem ser combinadas
#pragma omp parallel for
for (i=0; i<N; i++) A[i] = B[i] + C[i];</pre>

```
#pragma omp parallel for private(j)
for (i=0; i<N; i++) {
  for (j=0 ; j<M ; j++)
    M[i][j] = B[i] + C[j];
}</pre>
```

Só é privado o índice do ciclo imediatamente a seguir à directiva!!

## directiva for - collapse

 collapse (n) aplica-se a ciclos for aninhados, aumentando o número de iterações disponíveis para execução paralela

```
#pragma omp parallel for collapse (2)
for (r=0; r<N; r++) {
  for (c=0; c<N; c++) {
    for (k=0; k<N; k++) {
      M[r,c] = A[r,k] * B[k,c];
}
Só são privados os índices dos ciclos abrangidos pela directiva!!</pre>
```

### directiva parallel - if

- cláusula if (condição)
  - se condição != 0 então o grupo de threads é criado
  - se condição == 0 então execução sequencial

```
int i;
scanf ("%d", &i);
#pragma omp parallel if(i)
{
   printf("Hello!\n");
}
printf("program done\n");
```

### directiva single

Apenas a primeira thread a atingir o bloco single o executa Todas as threads sincronizam no fim do bloco (barreira implícita)

```
Sequencial
int n;
#pragma omp parallel
{ int tid;
                                   Paralelo
  tid = omp_get_thread_num();
#pragma omp single
  { n = omp_get_num_threads();
    printf ("%d threads\n", n);
                                   Sequencial
  printf (thread %d\n", tid);
                                   Paralelo
printf("program done\n");
                                    Sequencial
```

## controlo de acessos a dados partilhados

race conditions: o resultado depende da ordem de acesso a dados partilhados

```
int x=0;
#pragma omp parallel num_threads(2)
x = x+1;
```

#### Caso 1

. *T0:* lê x (valor 0)

. T0: calcula 0+1 = 1

. *T1:* lê x (valor 0)

. T0: escreve x=1

. *T1:* calcula 0+1 = 1

. T1: escreve x=1

#### Caso 2

. *TO:* lê x (valor 0)

. T0: calcula 0+1 = 1

. T0: escreve x=1

. *T1:* lê x (valor 1)

. T1: calcula 1+1 = 2

. T1: escreve x=2

### controlo de acessos a dados partilhados

directiva critical: apenas uma thread executa esse bloco em cada instante.

Execução sequencial desse bloco
int x=0;
#pragma omp parallel
 #pragma omp critical
 x = x+1;

As regiões críticas sem nome são consideradas a mesma região!

```
int x=0, y=0;
#pragma omp parallel
{
    #pragma omp critical
    x = x+1;
    #pragma omp critical
    y = y+1; }
```

```
int x=0, y=0;
#pragma omp parallel
{
    #pragma omp critical C1
    x = x+1;
    #pragma omp critical C2
    y = y+1; }
```

### controlo de acessos a dados partilhados

directiva atomic: garante que um endereço de memória é acedido de forma atómica. Pode ser vista como uma versão leve de critical.

Só se aplica a operações simples e ao lado esquerdo da atribuição.

Não garante que o lado direito da atribuição é avaliado de forma atómica.

```
int x=0;
#pragma omp parallel
    #pragma omp atomic
    x += 10;
```

```
int x=0;
#pragma omp parallel
{
    #pragma omp atomic
    x = 3 * x + 20/x;
}
```

 designa-se por redução uma operação que processa um conjunto de dados para a partir dele gerar um único valor, exemplo, a soma/máximo/produto de todos os elementos de um vector

```
int a[SIZE];
... inicializar a[]
int max=a[0];
#pragma omp parallel for
{
  for (i=0; i < SIZE; i++)
   if (a[i]>max) max=a[1]; }
```

max é uma variável partilhada

muito ineficiente NA verdade a execução é sequencial

```
int a[SIZE];
... inicializar a[]
int max=a[0];
#pragma omp parallel
\{int max\} = a[0];
 #pragma omp for
 for (i=0; i < SIZE; i++)
   if (a[i]>maxl) maxl=a[i];
 #pragma omp critical
 if (max1 > max) max = max1;
}
```

 A redução é tão comum que o OpenMP inclui uma cláusula específica (mas não para o máximo)

```
int a[SIZE];
... inicializar a[]
int sum=0;
#pragma omp parallel for reduction (+:sum)
{
  for (i=0; i < SIZE; i++)
    sum += a[i]; }</pre>
```

• A cláusula reduction aplica-se apenas a operações associativas.

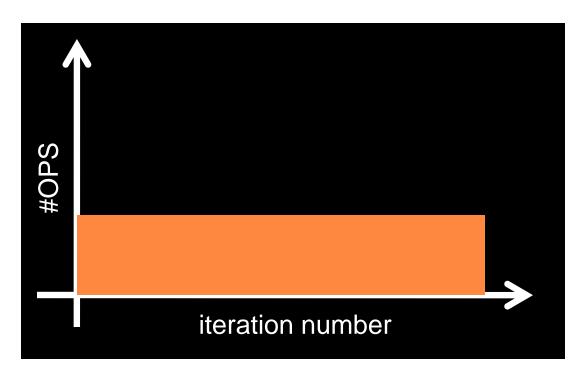
```
x = x op expr
x = expr op x (excepto subtracção)
x binop= expr
X++; ++X
x--; --x
x - variável escalar
expr - expressão escalar que não refere x
op - +, *, -, /, &, ^, |, &&, ||
binop - +, *, -, /, &, ^, |
```

 As operações sobre operando > ./prog double) não são associativas: sum= 1233458.0

```
float a[SIZE], sum=0.;
... inicializar a[]
#pragma omp parallel for re
{
  for (i=0; i < SIZE; i++)
    sum += a[i]; }
printf ("sum= %.1f\n", sum)</pre>
```

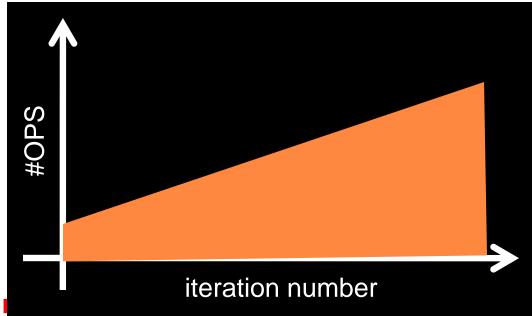
```
>./prog
sum = 1233463.0
sum = 1233457.0
```

• Problema A #pragma omp parallel for for (i=0; i < SIZE; i++) b[i] = a[i]\*a[i] + 10. / a[i]; Problema B #pragma omp parallel for private (j) for (i=0; i < SIZE ; i++) { b[i] = 1.F;for (j=2 ; j <= i ; j++)b[i] \*= j; } }



Problema A

```
#pragma omp parallel for
{
  for (i=0; i< SIZE; i++)
   b[i] = a[i]*a[i] + 10. / a[i]; }</pre>
```

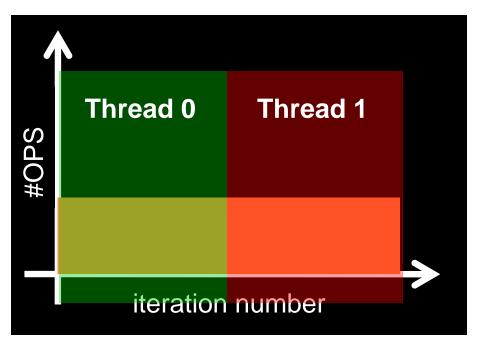


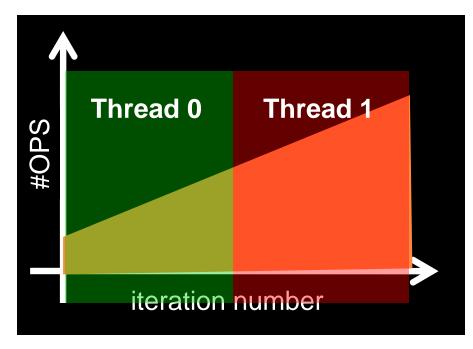
Problema B

```
#pragma omp parallel for
{
  for (i=0; i< SIZE; i++) {
    b[i] = 1.F;
    for (j=2; j<= i; j++)
    b[i] *= j; } }</pre>
```

#### #pragma omp parallel for schedule(static)

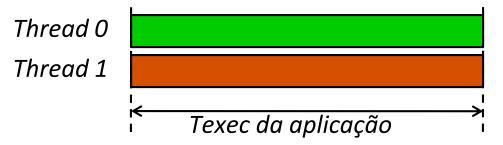
 O ciclo é dividido em #threads segmentos (chunks), todos com o mesmo número de iterações





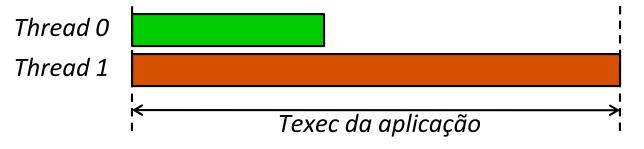
#### #pragma omp parallel for schedule(static)

#### 1 - carga uniforme para todas as iterações



carga **bem** distribuída

#### 2 - carga variável para diferentes iterações

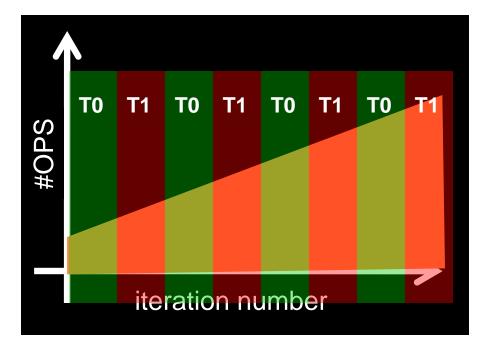


carga **mal** distribuída

#### #pragma omp parallel for schedule(dynamic)

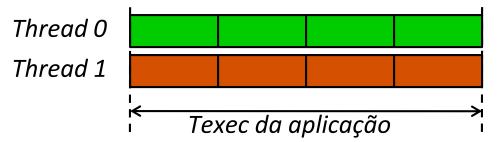
 O ciclo é dividido em muitos segmentos (chunks), todos com o mesmo número de iterações, e distribuídos pelas threads a pedido



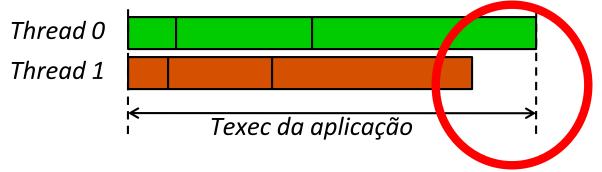


#### #pragma omp parallel for schedule(dynamic)

1 - carga uniforme para todas as iterações

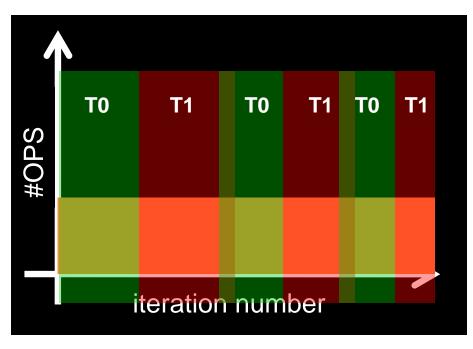


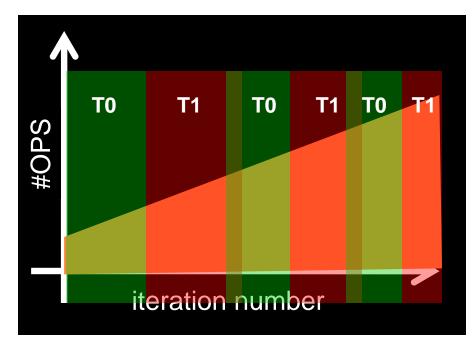
### 2 - carga variável para diferentes iterações



#### #pragma omp parallel for schedule(guided)

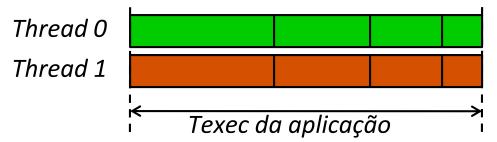
 O ciclo é dividido em muitos segmentos (chunks), cada vez com menor número de iterações, e distribuídos pelas threads a pedido



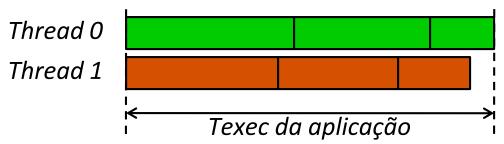


#### #pragma omp parallel for schedule(guided)

1 - carga uniforme para todas as iterações



### 2 - carga variável para diferentes iterações



### desempenho

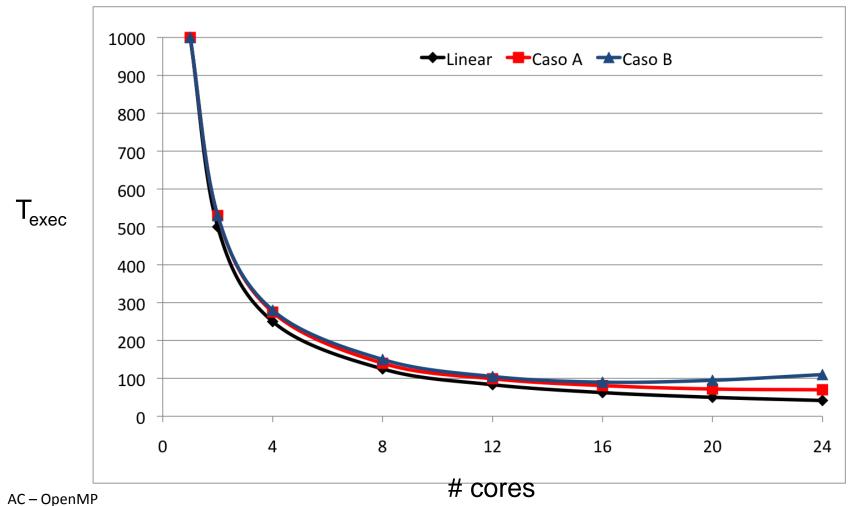
$$T_{exec} = \#I * CPI / f$$

 Com a programação multithreaded o número de instruções executadas aumenta, devido à gestão do paralelismo

CPI diminui, pois várias instruções são executadas simultaneamente

## desempenho – tempo de execução

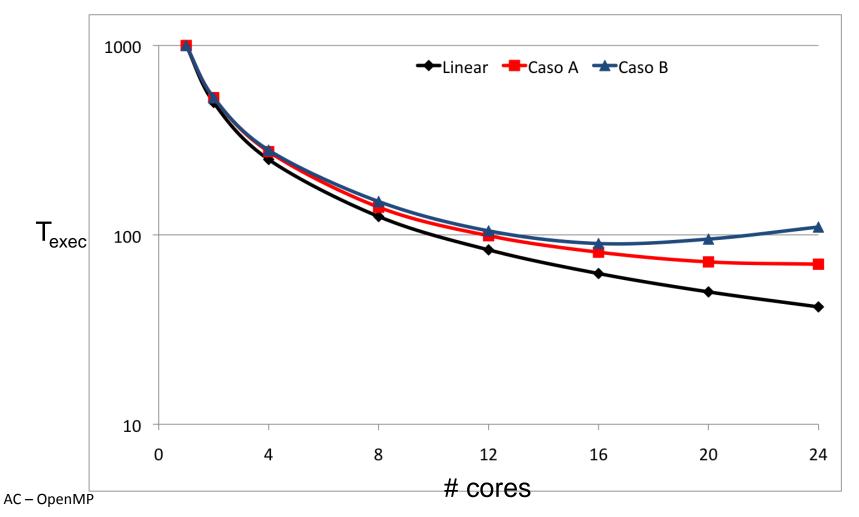
• OBJECTIVO: diminuir o tempo de execução



39

## desempenho – tempo de execução

### • Escala Logarítmica



## desempenho – speed up

$$S_p = \frac{T_1}{T_p}$$

*p* – número de processadores

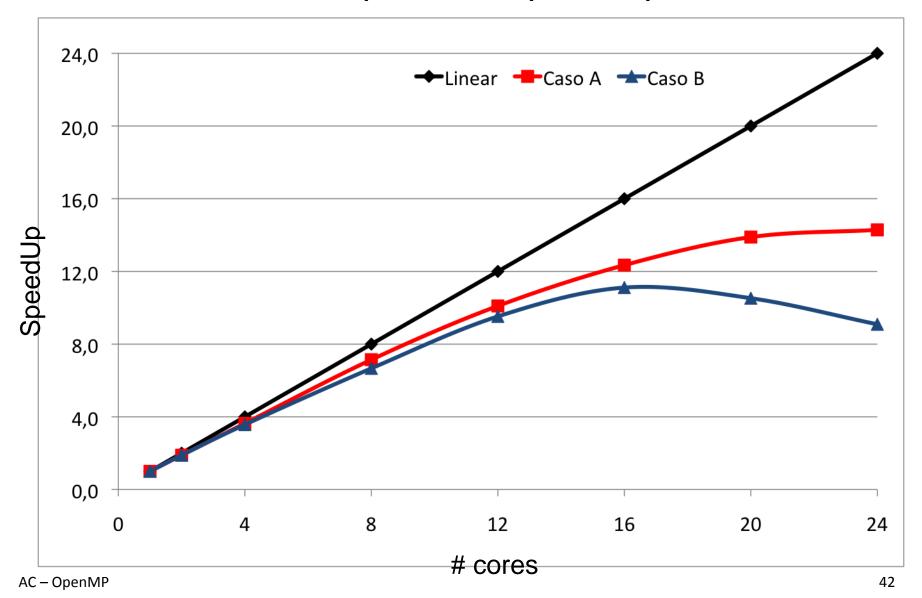
 $T_1$  – tempo de execução p=1

 $T_p$  – tempo de execução com p processadores

- indica quantas vezes mais rápida é a versão paralela com p processadores relativamente à versão sequencial
- O desafio está na escolha de T<sub>1</sub>:
  - deve-se usar o mesmo algoritmo mas apenas 1 processador?
  - deve-se usar o melhor algoritmo sequencial conhecido para aquele problema?

A resposta depende claramente do que se pretende avaliar com este ganho!

## desempenho – speed up



## Desempenho

Linear

$$T(p) = T(1) / p => lim (p-> \infty) T(p) = 0$$
  
 $S_p = p => lim (p-> \infty) S_p = \infty$ 

Caso A – no overheads

$$T(1) = T_{seq} + T_{par} = 100\% = 1$$
  
 $T(p) = T_{seq} + T_{par} / p => \lim (p-> \infty) T(p) = T_{seq}$   
 $S_p = 1 / (T_{seq} + T_{par} / p) => \lim (p-> \infty) S_p = 1 / T_{seq}$ 

Caso B – overheads

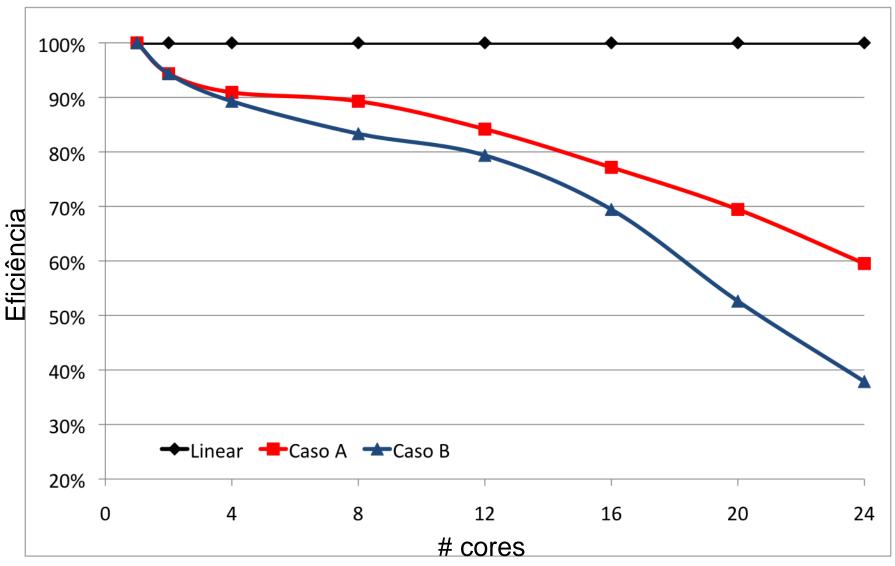
$$T(p) = T_{seq} + T_{par} / p + T_o (p) => lim (p-> \infty) T(p) = T_{seq} + T_o (\infty)$$
  
 $S_p = 1 / (T_{seq} + T_{par} / p + T_o (p)) => lim (p-> \infty) S_p = 1 / (T_{seq} + T_o (\infty))$ 

## desempenho – eficiência

$$E_p = \int_p^p \int_{S_p - speed \ up \ com \ p}^{p - n \'{u}mero \ de \ processadores}$$

- indica em que medida estão os p processadores a ser bem utilizados
- Razão entre o speed up observado e o ideal (=p)
- A utilização total efectiva dos processadores resultaria numa eficiência de 100%

## desempenho – eficiência



### desempenho

- O speed up observado é inferior ao linear (ou a eficiência é inferior a 100%) devido a vários custos (overheads) associados ao paralelismo:
  - gestão do paralelismo
  - replicação de trabalho
  - distribuição da carga
  - comunicação / sincronização