

# Estatística aplicada

Lino Costa

Departamento de Produção e Sistemas  
Escola de Engenharia  
lac@dps.uminho.pt

Ano letivo 2015/2016

# Sumário

1. Parâmetro e estatística
2. Inferência estatística
3. Estimação de parâmetros
  - tendência de um estimador
  - variância de um estimador
  - estimador de variância mínima
  - erro padrão e erro quadrático médio
  - consistência de um estimador
  - suficiência de um estimador
4. Distribuição amostral
  - distribuição amostral da média
  - teorema do limite central

# População e amostra

## População (ou Universo)

conjunto de indivíduos ou objetos que apresentam uma ou mais características em comum que se pretende analisar

## Amostra

subconjunto da população, que se observa com o objetivo de se obter informação sobre características desconhecidas da população de onde foi retirada

## Inferência estatística

- a população define um conjunto vasto, em geral, impossível de conhecer e a amostra constitui um subconjunto da população;
- uma amostra aleatória é uma amostra com  $n$  elementos independentes  $x_1, x_2, \dots, x_n$  em que a probabilidade de cada elemento ser selecionado é conhecida;
- o objetivo é, a partir da amostra aleatória, estabelecer conclusões para o todo representado pela população.

# Parâmetro e estatística

## Parâmetro

o parâmetro  $\theta$  é uma característica numérica, em geral, constante que descreve a população

## Exemplo 1

São exemplos de parâmetros a média ( $\mu$ ), a variância ( $\sigma^2$ ), a proporção ( $p$ ), o coeficiente de correlação ( $\rho$ )...

## Estatística

a estatística é uma característica numérica, calculada a partir dos valores observados na amostra, que descreve a amostra

## Exemplo 2

São exemplos de estatísticas a média amostral ( $\bar{x}$ ), a variância amostral ( $s^2$ ), a proporção amostral ( $\hat{p}$ ), o coeficiente de correlação ( $R$ )...

# Inferência estatística

A estatística inferencial refere-se a tomar decisões ou conclusões acerca da população através da análise da amostra

- estimação de parâmetros: estimar o valor de  $\theta$  desconhecido
  - estimação pontual: estimar o valor exato de  $\theta$  (por exemplo,  $\mu = 10$ )
  - estimação intervalar: estimar uma intervalo que inclua o verdadeiro valor de  $\theta$  com uma determinada probabilidade (por exemplo,  $7 < \mu < 13$ )
- testes de hipóteses: testar uma hipótese acerca de  $\theta$  (por exemplo,  $H_0 : \mu = 10$ )

# Estimação pontual

## Estimador pontual

A estimação pontual  $\hat{\theta}$  é uma estatística usada para estimar  $\theta$ .  
 $\hat{\theta}$  é uma variável aleatória porque uma estatística é uma variável aleatória

## Exemplo 3

Estimador pontual de  $\mu$ : média amostral  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$

## Estimativa pontual

O valor numérico de  $\hat{\theta}$  calculado com base numa determinada amostra aleatória é chamada de estimativa pontual de  $\theta$  (representada por  $\hat{\theta}$ ).

## Tendência de um estimador

### Estimador não tendencioso

Um estimador não tendencioso (ou não enviesado ou centrado) é um estimador pontual  $\hat{\theta}$  cujo valor esperado é igual ao valor verdadeiro de  $\theta$ .

$$E(\hat{\theta}) = \theta$$


### Tendência

A tendência de  $\hat{\theta}$  é a diferença entre o valor de esperado  $E(\hat{\theta})$  e o verdadeiro valor de  $\theta$ .

$$t_{\hat{\theta}}(\theta) = E(\hat{\theta}) - \theta$$

Quanto menor a tendência de um estimador mais **exato** é o estimador.

# Tendência de um estimador



## Exemplo 4

- $A$  é um estimador não tendencioso de  $\theta$ , i.e.,  $t_A(\theta) = E(A) - \theta = 0$
- $B$  é um estimador tendencioso de  $\theta$ , i.e.,  $t_B(\theta) = E(B) - \theta \neq 0$



# Tendência de um estimador

## Exemplo 5

Mostre que  $\frac{X}{n}$ , sendo  $X$  o número de sucessos em  $n$  tentativas, é um estimador não tendencioso do parâmetro  $p$  da distribuição binomial.

- para uma distribuição binomial com parâmetros  $n$  e  $p$ ,  $\mu = E(X) = np$
- $E(\frac{X}{n}) = \frac{1}{n} E(X) = p$ , logo  $t_{\frac{X}{n}}(p) = p - p = 0$

## Exemplo 6

Considere uma população com distribuição dada pela seguinte função densidade de probabilidade de uma variável aleatória  $x$ :

$f(x) = e^{-(x-\delta)}$ ,  $x > \delta$ . Mostre que  $\bar{x}$ , a média amostral de uma amostra retirada da população é um estimador tendencioso de  $\delta$ .

- $\mu = E(X) = \int_{\delta}^{\infty} x e^{-(x-\delta)} dx = [-x e^{-(x-\delta)}]_{\delta}^{\infty} - \int_{\delta}^{\infty} -e^{-(x-\delta)} dx = 1 + \delta$
- $E(\bar{X}) = \frac{E(X_1) + E(X_2) + \dots + E(X_n)}{n} = \frac{nE(X)}{n} = E(X) = 1 + \delta \neq \delta$ , logo  $\bar{x}$  é um estimador tendencioso de  $\delta$
- $E(\bar{X} - 1) = \delta$ , logo  $\bar{x} - 1$  é um estimador não tendencioso de  $\delta$

## Variância de estimadores

### Variância de um estimador

Quanto menor a variância  $V(\hat{\theta})$  de um estimador mais **preciso** é o estimador.

### Estimador não tendencioso de variância mínima


O estimador não tendencioso de variância mínima para  $\theta$  é não tendencioso e de menor variância. É o estimador, simultaneamente, mais exato e preciso do parâmetro  $\theta$ .

### Eficiência relativa de dois estimadores

Se  $\hat{\theta}_1$  e  $\hat{\theta}_2$  são dois estimadores não tendenciosos do parâmetro  $\theta$  de uma dada população e se a variância de  $V(\hat{\theta}_1)$  é menor que a variância de  $V(\hat{\theta}_2)$ , diz-se que  $\hat{\theta}_1$  é relativamente mais eficiente que  $\hat{\theta}_2$ .

$$efic(\hat{\theta}_1, \hat{\theta}_2) = \frac{V(\hat{\theta}_2)}{V(\hat{\theta}_1)}$$

# Variância de estimadores



## Exemplo 7

- $A$  e  $B$  são estimadores não tendencioso de  $\theta$ , i.e.,  $t_A(\theta) = E(A) - \theta = 0$  e  $t_B(\theta) = E(B) - \theta = 0$ , logo  $A$  e  $B$  são igualmente exatos.
- $V(A) < V(B)$ , logo  $A$  é mais preciso do que  $B$  para estimar  $\theta$ .
- $efic(A, B) = \frac{V(A)}{V(B)} < 1$ , logo  $A$  é mais eficiente do que  $B$ .

# Erro quadrático médio

## Erro padrão de um estimador

O erro padrão de um estimador  $\hat{\theta}$  é o desvio padrão do estimador  $\sigma_{\hat{\theta}} = \sqrt{V(\hat{\theta})}$ . O erro padrão pode ser estimado por  $s_{\hat{\theta}}$ , i.e.,  $\sigma_{\hat{\theta}} \approx s_{\hat{\theta}}$ .


## Erro Quadrático Médio (EQM)

Se  $\hat{\theta}$  não é um estimador não tendencioso de um dado parâmetro  $\theta$ , as comparações devem ser feitas com base no erro quadrático médio ( $EQM(\hat{\theta})$ ) em vez de apenas a variância  $V(\hat{\theta})$ .

$$EQM(\hat{\theta}) = E \left( (\hat{\theta} - \theta)^2 \right) = V(\hat{\theta}) + \left[ E(\hat{\theta}) - \theta \right]^2$$

Para estimadores não tendenciosos de  $\theta$ ,  $EQM(\hat{\theta}) = V(\hat{\theta})$ .

# Erro quadrático médio



## Exemplo 7

- $A$  é um estimador não tendencioso de  $\theta$ ,  $B$  e  $C$  são estimadores tendenciosos de  $\theta$ .
- $C$  é mais preciso do que  $A$  e este mais preciso que  $B$ , i.e.,  $V(C) < V(A) < V(B)$ .
- estimadores devem ser comparados em termos de  $EQM$ .

# Erro quadrático médio

$V(\hat{\Theta})$  pequena

$$E(\hat{\Theta}) = \theta$$



Exato e preciso...

$V(\hat{\Theta})$  grande




Exato e pouco preciso...

$$E(\hat{\Theta}) \neq \theta$$



Pouco exato e preciso...



Pouco exato e pouco preciso...

# Consistência de um estimador

O estimador  $\hat{\theta}$  é um estimador consistente do parâmetro  $\theta$  se e só se para cada  $c > 0$

$$\lim_{n \rightarrow \infty} P \left( \left| \hat{\theta} - \theta \right| < c \right) = 1$$

onde  $n$  é a dimensão da amostra aleatória. A consistência é uma propriedade assintótica.

Se  $\hat{\theta}$  é um estimador não tendencioso do parâmetro  $\theta$  e  $V(\hat{\theta}) \rightarrow 0$  à medida que  $n \rightarrow \infty$ , então  $\hat{\theta}$  é um estimador consistente de  $\theta$ .

## Exemplo 8

Mostre que a média amostral  $\bar{x}$  é um estimador consistente da média da população  $\mu$ .

- $$V(\bar{X}) = V\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{V(X_1) + V(X_2) + \dots + V(X_n)}{n^2} = \frac{nV(X)}{n^2} = \frac{V(X)}{n} = \frac{\sigma^2}{n} \rightarrow 0 \text{ quando } n \rightarrow \infty, \text{ logo } \bar{x} \text{ é um estimador consistente de } \mu.$$

## Suficiência de um estimador

O estimador  $\hat{\theta}$  é suficiente se usa toda a informação da amostra relevante para a estimação do parâmetro  $\theta$ ; i.e., se todo o conhecimento acerca de  $\theta$  que pode ser ganho a partir dos valores amostrais individuais e da sua ordem, pode também ser ganho pelo valor de  $\hat{\theta}$  por si só.

### Exemplo 9

O estimador  $\hat{y} = \frac{1}{2n} \sum_{i=1}^n Y_i$  calculado para uma amostra aleatória de tamanho  $2n$  não é suficiente pois não utiliza todo o conhecimento existente na amostra aleatória.



# Consistência e suficiência

Consistência



$$n \rightarrow \infty$$



Suficiência



Suficiente...



Não suficiente...

# Distribuição amostral

A distribuição amostral é a distribuição de probabilidade de uma estatística (uma função de variáveis aleatórias como a média amostral e a variância amostral). A distribuição amostral depende:

- da distribuição da população
- da dimensão da amostra
- do método de seleção da amostra

## Exemplo 13

A distribuição amostral da média amostral  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N(\mu, \frac{\sigma^2}{n})$  para uma amostra aleatória de  $n$  observações independentes,  $X_1, X_2, \dots, X_n \sim N(\mu, \sigma^2)$ .

## Distribuição amostral de $\bar{X}$

Considere uma amostra aleatória de dimensão  $n$  retirada de uma população normal com média  $\mu$  e variância  $\sigma^2$ , então a distribuição amostral  $\bar{X}$  é

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

Uma vez que  $X_1, X_2, \dots, X_n$  são independentes e normalmente distribuídas com a mesma média  $E(X) = \mu$  e variância  $V(X) = \sigma^2$ , a distribuição amostral de  $\bar{X}$  é normal com média e variância dadas por

$$\begin{aligned} E(\bar{X}) &= E\left(\frac{X_1 + X_2 + \dots + X_n}{n}\right) = \frac{1}{n}[E(X_1) + E(X_2) + \dots + E(X_n)] = \\ &= \frac{1}{n}[\mu + \mu + \dots + \mu] = \frac{n\mu}{n} = \mu \\ V(\bar{X}) &= V\left(\frac{X_1 + X_2 + \dots + X_n}{n}\right) = \frac{1}{n^2}[V(X_1) + V(X_2) + \dots + V(X_n)] = \\ &= \frac{1}{n^2}[\sigma^2 + \sigma^2 + \dots + \sigma^2] = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n} \end{aligned}$$

# Teorema do limite central

Considere uma amostra aleatória  $X_1, X_2, \dots, X_n$  de  $n$  observações independentes retirada de uma qualquer população com média  $\mu$  e variância  $\sigma^2$ , e então a distribuição limite da média amostral  $\bar{X}$  é

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right) \Rightarrow Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$$


à medida que  $n \rightarrow \infty$ . Esta aproximação normal da distribuição de  $\bar{X}$  é conhecida pelo Teorema do Limite Central.

## Aplicação


- **População normal** ( $X \sim N(\mu, \sigma^2)$ ) logo a distribuição de  $\bar{X}$  é normal, i.e.,  $\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$
- **População não normal com média  $\mu$  e variância  $\sigma^2$** 
  - **Amostra grande** ( $n \geq 30$ ) logo a distribuição de  $\bar{X}$  é normal, i.e.,  $\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$
  - **Amostra pequena** ( $n < 30$ ) logo a distribuição de  $\bar{X}$  não é normal

# Teorema do limite central


População



Uniforme






Exponencial






Normal

Distribuição da  
média de amostras  
de dimensão 5



Distribuição da  
média de amostras  
de dimensão 20



$n \rightarrow \infty$

# Teorema do limite central

## Exemplo 14

Suponha que as classificações, a nível nacional, do exame de Geografia, têm uma média de 14.3, com um desvio padrão 2.1. Assumindo que a distribuição é normal, calcule a probabilidade de que:

- i) um estudante, selecionado aleatoriamente, tenha uma classificação superior a 16 valores.
- ii) uma amostra aleatória de 10 estudantes tenha uma média superior a 16 valores.

- A população é normal
- i)  $X \sim N(\mu, \sigma^2)$  com  $\mu = 14.3$  e  $\sigma^2 = 2.1^2$
- $P(X > 16) = P\left(Z > \frac{16-14.3}{2.1}\right) = P(Z > 0.81) = 1 - P(Z \leq 0.81) = 1 - 0.7910 = 0.2090$
- ii)  $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$  com  $\mu = 14.3$ ,  $\sigma^2 = 2.1^2$  e  $n = 10$
- $P(\bar{X} > 16) = P\left(Z > \frac{16-14.3}{\frac{2.1}{\sqrt{10}}}\right) = P(Z > 2.56) = 1 - P(Z \leq 2.56) = 1 - 0.9948 = 0.0052$

# Teorema do limite central

## Exemplo 15

Uma máquina de enchimento de açúcar está regulada por forma a que a quantidade em cada pacote seja de 1000 gramas, com um desvio padrão de 50 gramas.

Qual a probabilidade de que a média de uma amostra de 36 pacotes seja menor que 980 gramas?

- A população não é normal
- $n = 36 \geq 30 \Rightarrow \bar{X} \sim N(\mu, \frac{\sigma^2}{n})$  com  $\mu = 1000$ ,  $\sigma^2 = 50^2$  e  $n = 36$
- $P(\bar{X} \leq 980) = P(Z \leq \frac{980 - 1000}{\frac{50}{\sqrt{36}}}) = P(Z \leq -2.41) = 0.0080$